

TALLER DE AUDITORÍA DE DATOS
Verificación primaria de fuentes para la construcción del Índice de Riesgo Municipal
Curso: Inteligencia de Negocios
Período de análisis: 2019 – 2025
Modalidad: Grupos | Herramienta: libre elección

1. Contexto del taller

A lo largo del curso hemos construido un pipeline de datos que integra seis fuentes primarias para analizar el riesgo en los municipios de Colombia: homicidios, secuestros, extorsión, actos terroristas, cultivos de hoja de coca y la división político-administrativa (DIVIPOLA). Sin embargo, un análisis de esta naturaleza solo es válido si las fuentes de datos que lo alimentan son confiables, completas, consistentes y oportunas.

Este taller tiene como propósito que usted realice de forma autónoma el proceso de auditoría primaria sobre esas seis fuentes de información, cubriendo el período comprendido entre 2019 y 2025. Adicionalmente, se le pide que proponga dos fuentes nuevas que puedan enriquecer el índice de riesgo que construiremos más adelante en el curso.

¿Qué es una auditoría primaria de datos?
Es el proceso de verificar, antes de cualquier análisis, que los datos son lo que dicen ser. Incluye diagnosticar su completitud, exactitud, consistencia, oportunidad, unicidad y validez. Una auditoría bien ejecutada es la diferencia entre un índice creíble y uno que nadie va a usar para tomar decisiones.

2. Fuentes de datos a auditar

Las siguientes son las seis fuentes primarias que debe auditar. Para cada una se indica dónde puede descargar los datos, el período que debe cubrir y las variables más relevantes que se espera encontrar.

#	Fuente	Entidad responsable	Variables clave esperadas	Período
1	Homicidios	Policía Nacional — SIEDCO / datos.gov.co	Municipio, departamento, código DANE, fecha, número de víctimas	2019–2025
2	Secuestros	Policía Nacional — SIEDCO / datos.gov.co	Municipio, departamento, código DANE, fecha, modalidad, número de víctimas	2019–2025
3	Extorsión	Policía Nacional — SIEDCO / datos.gov.co	Municipio, departamento, código DANE, fecha, número de casos	2019–2025
4	Actos terroristas	Policía Nacional / Fuerzas Militares — DIRAN	Municipio, departamento, código DANE, fecha, tipo de acto	2019–2025
5	Cultivos de hoja de coca	UNODC – SIMCI / OCHA Colombia	Municipio, código DANE, año, hectáreas detectadas	2019–2025
6	División político-administrativa	DANE — DIVIPOLA	Código DANE (5 dígitos), nombre municipio, departamento, región	Vigente 2025

Sobre la disponibilidad de datos al año 2025
Si los datos de 2025 no están disponibles para una fuente específica, documente ese hecho en su informe indicando cuál es el último año disponible, cuándo se espera la actualización y qué impacto tiene ese rezago sobre el análisis y que propone para subsanar este aspecto.

3. Proceso de auditoría — Paso a paso

Para cada una de las seis fuentes listadas en la sección anterior, usted debe ejecutar los siguientes pasos en el orden indicado. Puede usar la herramienta de su preferencia: Python, R, Excel, Power BI, KNIME o cualquier combinación que justifique. Lo importante es que cada hallazgo quede documentado.

Paso 1 — Descarga y registro de la fuente

Antes de abrir el archivo, registre la siguiente información sobre la fuente:

1. URL exacta de descarga o ruta del archivo.
2. Fecha en que descargó el archivo (no la fecha de los datos, sino cuándo lo descargó usted).
3. Formato del archivo: CSV, XLSX, JSON, API, etc.
4. Tamaño del archivo en MB.
5. Número de filas y columnas antes de cualquier modificación.

TIP PYTHON — Registrar metadatos de descarga en Python

```
import os, datetime
print('Descargado el:', datetime.datetime.now().strftime('%Y-%m-%d %H:%M'))
print('Tamaño (MB):', round(os.path.getsize('archivo.csv') / 1e6, 2))
df = pd.read_csv('archivo.csv')
print('Filas:', df.shape[0], '| Columnas:', df.shape[1])
```

Paso 2 — Exploración inicial de la estructura

Una vez cargado el archivo, explore su estructura sin modificar nada todavía. El objetivo es entender qué contiene el archivo tal como viene de la fuente.

6. ¿Cuáles son los nombres exactos de las columnas?
7. ¿Qué tipo de dato tiene cada columna (texto, número, fecha, booleano)?
8. ¿Hay columnas con nombres ambiguos que requieran buscar un diccionario de datos?
9. ¿Los encabezados están en la primera fila o hay filas de título antes?
10. ¿El separador de decimales es punto o coma? ¿El separador de miles es punto o coma?

TIP PYTHON — Exploración inicial de estructura

```
print(df.dtypes)      # tipo de dato por columna
print(df.columns.tolist()) # nombres exactos
df.head(5)           # primeras filas
df.tail(5)            # últimas filas — detecta filas de totales al final
df.sample(10)         # muestra aleatoria — revela casos extremos
```

Paso 3 — Diagnóstico de completitud

La completitud evalúa si todos los registros esperados están presentes y si todos los campos obligatorios tienen valor.

11. Cuente el número de valores nulos por columna y calcule el porcentaje sobre el total de filas.
12. ¿Hay años del período 2019–2025 que no aparecen en el dataset? ¿Hay meses faltantes?
13. ¿Hay departamentos o municipios que nunca aparecen? ¿Es esperable o es un error?
14. Compare el número de municipios únicos en el dataset contra los 1.122 municipios de Colombia según DIVIPOLA.

TIP PYTHON — Diagnóstico de completitud

```
nulos = df.isnull().sum()
```

```
pct = (nulos / len(df) * 100).round(2)
pd.DataFrame({'nulos': nulos, 'porcentaje': pct})
# Verificar años presentes
df['anio'].value_counts().sort_index()
# Municipios únicos vs esperados
print('Municipios únicos:', df['cod_municipio'].nunique(), '/ 1122 esperados')
```

Paso 4 — Diagnóstico de exactitud y validez

La exactitud verifica que los valores son correctos dentro del dominio esperado. La validez verifica que los valores tienen el formato y rango correcto.

15. ¿Existen valores negativos en columnas de conteos (número de víctimas, hectáreas)?
16. ¿Existen valores extremos que parezcan errores de digitación (ej: 99.999 homicidios en un municipio rural)?
17. ¿Los códigos DANE tienen exactamente 5 dígitos? ¿Hay códigos con 4 dígitos a los que les falta el cero inicial?
18. ¿Las fechas tienen un formato consistente en todas las filas? ¿Hay fechas fuera del rango 2019–2025?
19. ¿Los nombres de departamentos y municipios están escritos de forma consistente (tildes, mayúsculas, abreviaturas)?

TIP PYTHON — Detección de valores fuera de rango

```
# Valores negativos en columnas numéricas
cols_num = df.select_dtypes(include='number').columns
for col in cols_num:
    print(col, '| negativos:', (df[col] < 0).sum())
# Verificar longitud del código DANE
df['cod_municipio'].astype(str).str.len().value_counts()
# Fechas fuera de rango
df['fecha'] = pd.to_datetime(df['fecha'], errors='coerce')
print('Antes de 2019:', (df['fecha'].dt.year < 2019).sum())
print('Después de 2025:', (df['fecha'].dt.year > 2025).sum())
```

TIP PYTHON — Detección de outliers con el método IQR

```
Q1 = df['columna'].quantile(0.25)
Q3 = df['columna'].quantile(0.75)
IQR = Q3 - Q1
outliers = df[df['columna'] > Q3 + 1.5 * IQR]
print(f'Outliers detectados: {len(outliers)}')
print(outliers[['cod_municipio', 'fecha', 'columna']].head(10))
```

Paso 5 — Diagnóstico de consistencia

La consistencia verifica que los datos son coherentes internamente y entre fuentes distintas.

20. ¿El nombre del municipio y su código DANE coinciden con los registros de DIVIPOLA?
21. ¿Un mismo municipio aparece con nombres distintos en el mismo archivo? (ej: "Bogotá", "BOGOTA", "Bogota D.C.")
22. ¿Los totales por año y departamento son coherentes con los datos desagregados por mes y municipio?
23. ¿Los mismos municipios que aparecen en homicidios aparecen también en las otras fuentes de delitos?

TIP PYTHON — Verificación de consistencia entre fuentes

```
# Códigos en homicidios que no están en DIVIPOLA
```

```

codigos_div = set(divipola['cod_municipio'])
codigos_homici = set(df_homicidios['cod_municipio'].astype(str).str.zfill(5))
huerfanos = codigos_homici - codigos_div
print(f'Códigos sin match en DIVIPOLA: {len(huerfanos)}')
# Municipio con múltiples nombres
df.groupby('cod_municipio')['nombre_municipio'].nunique().sort_values(ascending=False).head()

```

Paso 6 — Diagnóstico de unicidad

La unicidad verifica que no existen filas duplicadas que inflen artificialmente los conteos.

24. ¿Hay filas completamente idénticas en todas sus columnas?
25. ¿Hay filas con el mismo municipio, misma fecha y mismo valor pero con diferente identificador? (duplicado lógico)
26. ¿Si se suman los registros duplicados cuánto representan sobre el total?

TIP PYTHON — Detección de duplicados

```

# Duplicados exactos
print('Filas duplicadas:', df.duplicated().sum())
# Duplicados lógicos (mismo municipio + fecha + valor)
cols_clave = ['cod_municipio', 'anio', 'mes', 'cantidad']
dup_logicos = df.duplicated(subset=cols_clave, keep=False)
print('Duplicados lógicos:', dup_logicos.sum())
df[dup_logicos].sort_values(cols_clave).head(10)

```

Paso 7 — Diagnóstico de oportunidad

La oportunidad evalúa si los datos están disponibles en el momento en que se necesitan para el análisis y si el rezago entre la ocurrencia del hecho y su publicación es aceptable.

27. ¿Cuál es el último período (año/mes) disponible en el dataset descargado?
28. ¿Existe un rezago entre la fecha del último dato y la fecha actual? ¿De cuántos meses?
29. ¿La fuente tiene una frecuencia de actualización documentada (mensual, trimestral, anual)?
30. ¿Para el año 2025 hay datos disponibles o aún no han sido publicados?

TIP PYTHON — Calcular el rezago de actualización

```

import datetime
hoy = datetime.date.today()
ultimo_anio = int(df['anio'].max())
ultimo_mes = int(df.loc[df['anio']==ultimo_anio, 'mes'].max())
ultimo_dato = datetime.date(ultimo_anio, ultimo_mes, 1)
rezago_dias = (hoy - ultimo_dato).days
print(f'Último dato: {ultimo_dato} | Rezago: {rezago_dias} días')

```

4. Propuesta de dos fuentes nuevas

Además de auditar las seis fuentes primarias existentes, usted debe identificar y proponer dos fuentes de información adicionales que puedan enriquecer el índice de riesgo municipal. Estas fuentes deben ser públicas, verificables y relevantes para el fenómeno que se está midiendo.

Para cada fuente propuesta debe documentar los siguientes aspectos:

Aspecto	Descripción de lo que se espera
---------	---------------------------------

Nombre de la fuente	Nombre oficial de la base de datos o indicador
Entidad responsable	Quién la produce y la mantiene
URL de acceso	Enlace directo a la descarga o consulta
Variabes relevantes	Qué columnas o indicadores contiene que son útiles para el índice
Período disponible	Desde qué año está disponible y con qué frecuencia se actualiza
Justificación	Por qué esta fuente enriquece el índice: qué dimensión del riesgo captura que las fuentes actuales no capturan
Limitaciones conocidas	Rezago, cobertura geográfica parcial, subregistro u otras advertencias
Nivel de dificultad de integración	Fácil / Media / Alta — y por qué

Orientación para encontrar fuentes nuevas

Piense en dimensiones del riesgo que las fuentes actuales NO capturan. Algunos ejemplos de categorías a explorar:

- Presencia institucional del Estado en el municipio (índice de presencia estatal, PDET)
- Condiciones socioeconómicas (NBI, GINI municipal, tasa de desempleo)
- Desplazamiento forzado (UARIV — Registro Único de Víctimas)
- Infraestructura de conectividad (vías terciarias, acceso a servicios básicos)
- Alertas tempranas (Defensoría del Pueblo — Sistema de Alertas Tempranas)

No es necesario que la fuente sea perfecta. Lo importante es que argumente sólidamente por qué aporta al índice.

5. Entregables del taller

Al finalizar el taller debe entregar los siguientes productos a través de la plataforma virtual en los formatos indicados:

1 Informe de auditoría (PDF)

Un documento que consolide los resultados del diagnóstico para las seis fuentes. Para cada fuente debe incluir una tabla resumen con las seis dimensiones de calidad evaluadas (completitud, exactitud, validez, consistencia, unicidad, oportunidad), los hallazgos encontrados, la decisión propuesta para tratar cada problema y los registros afectados.

2 Tabla resumen de hallazgos (XLSX)

Una tabla con una fila por hallazgo encontrado, con columnas: fuente, dimensión de calidad, descripción del problema, número de registros afectados, porcentaje sobre el total y decisión propuesta de tratamiento.

6. Criterios de evaluación

Criterio	Descripción	Peso
Cobertura del diagnóstico	Se auditaron las 6 fuentes con las 6 dimensiones de calidad en todas las temporalidades solicitadas (2019–2025)	25 %
Profundidad del análisis	Los hallazgos van más allá de contar nulos. Se identifican inconsistencias cruzadas entre fuentes, patrones de subregistro, cambios metodológicos entre años y variaciones en la cobertura geográfica.	25 %
Decisiones de tratamiento	Para cada problema encontrado se propone una decisión concreta y justificada: eliminar, imputar, corregir, documentar o escalar a la fuente.	20 %
Calidad de las fuentes nuevas propuestas	Las dos fuentes propuestas son pertinentes, accesibles, bien documentadas y su justificación es sólida y técnicamente argumentada.	20 %
Claridad y organización del informe	El informe es legible, tiene estructura clara, las tablas son comprensibles para alguien que no participó en el análisis y los datos están correctamente citados.	10 %

Advertencia sobre el uso de IA generativa

El uso de herramientas de IA (ChatGPT, Copilot, Gemini, etc.) para apoyar la redacción está permitido siempre que el análisis de datos sea propio.

No es válido entregar un informe generado por IA que describa datos que usted no exploró directamente. El docente puede solicitar que sustente verbalmente cualquier hallazgo del informe.

Si usó IA como apoyo, debe declararlo al inicio del documento indicando para qué la usó.

7.2 Referencias metodológicas para auditoría de datos

- Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5–33.
- Batini, C., Cappiello, C., Francalanci, C., & Maurino, A. (2009). Methodologies for data quality assessment and improvement. *ACM Computing Surveys*, 41(3), 1–52.
- DANE (2023). Metodología del Marco Geoestadístico Nacional — DIVIPOLA. Bogotá: DANE.
- UNODC-SIMCI (2024). Colombia: Monitoreo de territorios afectados por cultivos ilícitos 2023. Bogotá: UNODC.

7.3 TIPS adicionales de Python para el taller

TIP PYTHON — Comparar dos fuentes por código de municipio

```
# Códigos que están en homicidios pero NO en DIVIPOLA
solo_homici = set(df_hom['cod']) - set(df_div['cod'])
# Códigos que están en DIVIPOLA pero NO en homicidios
solo_div = set(df_div['cod']) - set(df_hom['cod'])
print(f'Sin match en DIVIPOLA: {len(solo_homici)}')
print(f'Municipios sin ningún homicidio registrado: {len(solo_div)}')
```

```

TIP PYTHON — Verificar cobertura temporal por fuente
# Combinaciones año-mes presentes en el dataset
cobertura = df.groupby(['anio', 'mes']).size().reset_index(name='registros')
# Detectar meses faltantes en el período 2019-2025
esperados = pd.MultiIndex.from_product(
    [range(2019, 2026), range(1, 13)], names=['anio', 'mes']
)
faltantes = esperados.difference(
    pd.MultiIndex.from_frame(cobertura[['anio', 'mes']])
)
print(f'Períodos faltantes: {len(faltantes)}')

```

```

TIP PYTHON — Construir la tabla resumen de hallazgos automáticamente
hallazgos = []
# Por cada hallazgo encontrado durante el análisis:
hallazgos.append({
    'fuente' : 'homicidios',
    'dimension' : 'Compleitud',
    'descripcion' : 'Columna cod_municipio tiene 342 nulos (2.1%)',
    'n_registros' : 342,
    'pct' : 2.1,
    'decision' : 'Excluir del análisis — no se puede imputar un código DANE'
})
df_hallazgos = pd.DataFrame(hallazgos)
df_hallazgos.to_excel('hallazgos_auditoria.xlsx', index=False)

```

```

TIP PYTHON — Exportar el informe de calidad por fuente
resumen = []
for fuente, df_f in fuentes.items():
    resumen.append({
        'fuente' : fuente,
        'filas' : len(df_f),
        'columnas' : df_f.shape[1],
        'nulos_total' : df_f.isnull().sum().sum(),
        'duplicados' : df_f.duplicated().sum(),
        'anio_min' : df_f['anio'].min() if 'anio' in df_f else 'N/D',
        'anio_max' : df_f['anio'].max() if 'anio' in df_f else 'N/D',
    })
pd.DataFrame(resumen)

```

— Éxitos en el desarrollo del taller —